



DETECȚIA ANOMALIILOR ÎN IMAGINI HIPERSPECTRALE BAZATĂ PE REPREZENTARE DE RĂNG REDUS ȘI REPREZENTARE RARĂ (SPARSE)

BĂNICĂ ALEXANDRU • ROTONDO ANDREA

BUCUREȘTI • 2026



LRASR

Low-Rank + Sparse Representation

Cuprins



1. Prezentarea problemei

2. Metode clasice de detectare a anomaliilor în HSI

3. Low-rank and sparse representation

4. Linearized Alternating Direction Method with Adaptive Penalty (LADMAP)

5. Construirea dicționarului D


6. Testarea modelelor de detecție

7. Concluzii

8. AI Report Usage

Problematica abordată

- Detectarea anomaliilor în imaginile hiperspectrale (HSI) este o problemă importantă în teledetecție.
- Materialele reflectă energia electromagnetică diferit la anumite lungimi de undă specifice.
- HSI permite identificarea obiectelor sau zonelor diferite de fundal, în aplicații militare și civile.



Ținte vs. anomalii spectrale

DETECTAREA ȚINTELOR

Scopul detectării țintelor este identificarea unor semnături spectrale specifice în imagine.



DETECTAREA ANOMALIILOR

Pixelii cu semnătură spectrală diferită față de pixelii de fundal din vecinătate sunt considerați anomalii.

Metode clasice de detectare a anomaliilor în HSI

Primele metode pornesc de la ideea că pixelii anormali au o semnătură spectrală diferită față de fundalul din jur.

RX / REED-XIAOLI

Presupune că fundalul urmează o distribuție normală multivariată.


Măsoară diferența unui pixel față de vecinii lui folosind distanța Mahalanobis.

PROBLEMA

În imaginile reale, fundalul este mult mai complex și nu poate fi descris corect printr-un model statistic simplu.

EXTENSII

- Regularized RX
- Segmented RX
- Kernel RX
- SRD — Sparse Representation Detector



Variante îmbunătățite ale RX și metode sparse

Regularized RX

Regularizează matricea de covarianță pentru a deveni mai stabilă și mai robustă, reducând influența zgomotului și a valorilor extreme.

Segmented RX

Împarte imaginea în clustere / regiuni similare și aplică RX separat pe fiecare cluster, astfel fundalul este modelat local.


Kernel RX

Folosește metode kernel pentru a proiecta datele într-un spațiu de dimensiune mai mare, unde pot fi surprinse relații neliniare.

SRD

Pixelii normali sunt reprezentați prin câțiva atomi dintr-un dicționar de fundal. Eroarea mare de reconstrucție indică o anomalie.

Limitări ale algoritmilor clasici



- Metodele bazate pe reprezentare folosesc un dicționar de semnături spectrale pentru a reconstrui pixelii imaginii.
- SRD presupune că un pixel normal poate fi reprezentat folosind doar câțiva atomi importanți din dicționar.
- Collaborative Representation Detector aproximează fundalul folosind pixelii vecini, iar anomaliile nu se reconstruiesc corect.
- Limitarea principală: aceste metode analizează mai ales relațiile locale și nu folosesc suficient informația globală a întregii imagini.

Consecință: performanța scade în scene complexe, cu multe materiale diferite.

Low-rank and sparse representation

În HSI, pixelii de fundal sunt corelați și pot fi reprezentați folosind alți pixeli de fundal. Pixelii anormali rămân în reziduu.

X

imaginea HSI


D · S

fundal reconstruit

E

reziduu / anomalii

$$X = D S + E$$



Descompunerea matriceală

Considerăm că un număr de N pixeli formează o imagine hiperspectrală. Matricea X poate fi descompusă într-o componentă de fundal și o componentă de anomalie:

$$X = D S + E$$

$D \cdot S$

partea de fundal reconstruită

$D = [d_1, d_2, \dots, d_m]$

dicționarul de fundal format din pixeli de fundal; m = numărul de atomi

$S = [s_1, s_2, \dots, s_n]$

coeficienții de reprezentare

$E = [e_1, e_2, \dots, e_n]$

partea rămasă, corespunzătoare anomaliilor

Datele originale pot fi reconstruite folosind dicționarul de fundal. Ce nu se reconstruiește bine rămâne în E .

Problema LRR: rang redus + anomalii rare

Pe de o parte, doar o fracțiune foarte mică dintre pixeli sunt anomalii $\Rightarrow$ matricea E este sparse. Pe de altă parte, spectrele HSI provin din mai multe subspații $\Rightarrow$ coeficienții S trebuie să aibă rang minim.

$$\min_{\{S,E\}} \text{rank}(S) + \lambda \|E\|_{2,1} \quad \text{supusă constrângerii} \quad X = D S + E$$

$\text{rank}(\cdot)$

funcția de rang — impune reprezentarea low-rank.

$\lambda > 0$

parametru de echilibru între fundal și anomalie.

$\|\cdot\|_{2,1}$

normă folosită pentru componenta rară E .

Cum citim formula

LOW-RANK: $\text{rank}(S)$

- fundalul este organizat
- compact
- corelat
- majoritatea pixelilor seamănă între ei

S = partea de fundal

SPARSE: $\|E\|_{2,1}$

- matricea anomaliilor are multe zerouri
- doar câteva valori mari
- foarte puțini pixeli sunt anomalii

E = partea de anomalii

„Reconstruiesc imaginea folosind fundalul normal și corelat. Tot ce NU poate fi reconstruit bine devine anomalie.”

De ce folosim LRR și NU RPCA?

Întrebarea importantă: dacă RPCA separă imaginea în fundal low-rank + anomalie sparse, de ce mai avem nevoie de LRR?

LRR vs. RPCA

RPCA

- separă imaginea în fundal low-rank și erori/anomalii sparse
- presupune că toate datele aparțin unui singur subspațiu low-rank
- implică un fundal „de același tip”

image = fundal + anomalie

LRR

- generalizează RPCA
- poate modela multiple subspații simultan
- descrie separat vegetație, apă, asfalt, clădiri, sol etc.
- este mai potrivit pentru HSI reale

În HSI, fiecare material are propriul comportament spectral și formează propriul „grup” / subspațiu.

LADMAP Algorithm

Linearized Alternating Direction Method with Adaptive Penalty

1 Problema originală

$\text{rank}(S)$ este dificil de optimizat direct.

2 Relaxare

$\text{rank}(S)$ este înlocuit cu nuclear norm $\|S\|_*$.

3 Actualizări iterative

Se actualizează S , componenta sparse și E .

4 Penalty adaptiv

Penalizarea se ajustează pentru convergență.

$\|S\|_*$ (nuclear norm) = aproximare a rangului. Păstrează ideea de low-rank, dar face formula rezolvabilă matematic.

$$\begin{aligned} \min_{S, E} \quad & \|S\|_* + \lambda \|E\|_{2,1} \\ \text{s.t} \quad & X = DS + E \end{aligned}$$

Sparse regularization peste modelul Low-Rank

LOW-RANK · STRUCTURĂ GLOBALĂ

- relațiile dintre toți pixelii
- structura mare a imaginii
- tiparele generale ale fundalului

SPARSE · STRUCTURĂ LOCALĂ

- fiecare material are caracteristici proprii
- fiecare pixel seamănă mai mult cu anumite tipuri de pixeli
- pixelul este reprezentat doar prin câțiva pixeli relevanți, nu prin toți atomii

Sparse representation forțează coeficienții inutili să devină 0 și păstrează doar cei mai importanți coeficienți.

Noua formulă LRASR

$$\min_{\{S,E\}} \|S\|^* + \beta \|S\|_1 + \lambda \|E\|_{2,1}$$

$$\|S\|^*$$

LOW-RANK

modelează structura globală; păstrează corelațiile dintre pixeli; descrie fundalul general.

$$\beta \|S\|_1$$

SPARSE REGULARIZATION

face coeficienții rari; păstrează doar atomii relevanți; modelează structura locală.

$$\lambda \|E\|_{2,1}$$

REZIDUU / ANOMALII

detectează anomalii; produce reziduul.

Modelul final combină informația globală și locală.

Crearea dicționarului D

DE CE CONTEAZĂ?

- Dicționarul de fundal D joacă un rol esențial în detectarea anomaliilor.
- În detectarea anomaliilor, dicționarul nu este cunoscut în avans.
- Trebuie construit automat astfel încât să descrie cât mai bine fundalul imaginii.

DE CE NU TOȚI PIXELII / RANDOM?

- folosirea tuturor pixelilor crește costul computațional;
- selectarea aleatoare poate favoriza materialele dominante;
- materialele mai puțin reprezentate pot fi ignorate;
- anomaliile pot ajunge în dicționar.

Soluția: construire a dicționarului bazată pe clustering.

Strategia de construire a dicționarului


- 1 K-Means** Imaginea este împărțită în K clustere pentru a reprezenta toate tipurile de materiale din scenă.
- 2 Mahalanobis** În fiecare cluster se calculează distanța Mahalanobis pentru fiecare pixel, folosind principiul detectorului RX.
- 3 Selecție fundal** Pixelii cu valori mici sunt considerați fundal de încredere; valorile mari pot fi anomalii, zgomot sau materiale rare.
- 4 Atomi D** Din fiecare cluster sunt selectați pixelii cu cele mai mici distanțe pentru a forma atomii dicționarului.

Rezultat: dicționarul conține exemple reprezentative pentru toate clasele de fundal și reduce probabilitatea includerii anomaliilor.

Testarea modelelor de detecție




AUC pentru cele trei seturi de testare — $\lambda = \beta = 0.1$

Metodă	Set 1	Set 2	Set 3
Global-RX	0.9853	0.8409	0.9384
SegRX	0.9890	0.8616	0.5542
SRD	0.9759	0.8045	0.8961
RPCA-RX	0.9632	0.8689	0.9655
LRASR	0.9923	0.9798	0.9848









LRASR are cel mai bun AUC pe toate cele trei experimente.

Receiver Operating Characteristic (ROC)



Curbele ROC compară rata de detecție cu rata alarmelor false. AUC mai mare înseamnă separare mai bună între fundal și anomalie.

Rezultate vizuale și comparații



Concluzii

- Este propusă metoda LRASR (Low-Rank and Sparse Representation) pentru detectarea anomaliilor în imagini hiperspectrale.
- Fundalul este modelat printr-un dicționar de fundal, iar coeficienții de reprezentare au proprietatea de rang redus.
- Se introduce regularizarea sparse pentru a descrie mai precis structura locală a fiecărui pixel.
- Autorii propun o nouă metodă de construire a dicționarului, care reduce probabilitatea includerii anomaliilor și asigură reprezentarea tuturor claselor de materiale.
- Anomaliile sunt identificate din reziduul de reconstrucție obținut după reprezentarea fundalului.
- Rezultatele experimentale arată că LRASR depășește performanța metodelor clasice de detectare a anomaliilor.
- O limitare importantă este costul computațional ridicat.

AI Report Usage

Cum ne-a ajutat AI-ul în pregătirea proiectului

Înțelegerea conceptelor

- explicarea pe pași a diferenței dintre RX, RPCA, LRR și LRASR
- clarificarea termenilor: low-rank, sparse, normă nucleară, normă $L_{2,1}$, reziduu
- interpretarea formulelor și a rolului parametrilor λ și β

Implementare & verificare

- structurarea pașilor de implementare pentru metoda bazată pe dicționar
- explicarea ideii de clustering K-Means + distanță Mahalanobis
- interpretarea curbelor ROC și a valorilor AUC

Optimizare cod & conversie

- sprijin în finisarea și adaptarea codului MATLAB preluat dintr-un repo GitHub
- identificarea logicii algoritmice și verificarea funcționalității înainte de rulare
- transformarea și explicarea codului din MATLAB în Python pentru o implementare mai accesibilă

Bibliografie

- Xu, Y., Wu, Z., Li, J., Plaza, A., Wei, Z. “Anomaly Detection in Hyperspectral Images Based on Low-Rank and Sparse Representation”, IEEE Transactions on Geoscience and Remote Sensing, 2016. DOI: 10.1109/TGRS.2015.2493201
- Repo GitHub: axiqia / Anomaly-Detection-in-Hyperspectral-Images-Based-on-Low-Rank-and-Sparse-Representation
- San Diego (AVIRIS hyperspectral scene) dataset
- HYDICE Urban Dataset